研究計画：バブル型クラスタ学習による GateRAF 強化と 脳 fMRI タスク予測

目次

1 背景 2
- 1.1 脳 fMRI タスク予測の意義と困難さ 2
- 1.2 使用データセット 2

2 課題：既存手法の限界 3
- 2.1 既存手法 1：単純な時系列予測モデル 3
- 2.2 既存手法 2：RAF による他者参照 3

3 解決手段：2 段階バブル型 GateRAF 4
- 3.1 全体設計の概要 4
- 3.2 記号の定義 4
- 3.3 Phase 1：対照学習によるバブル形成 4
- 3.4 Phase 2：GateRAF による参照学習 6

4 予想される成果 7
- 4.1 比較実験の設計 7
- 4.2 期待される効果 8

1　背景

1.1　脳 fMRI タスク予測の意義と困難さ

ヒトがワーキングメモリタスクを実行しているとき，神経活動は血中酸素レベル依存（BOLD）信号として fMRI に記録される．この時系列から正答率や反応時間といった行動成績を予測できれば，認知機能の個人差や障害の客観的評価につながる．

しかし fMRI 時系列は，予測モデルの構築を困難にする 3 つの性質を持つ．

スパイク性 刺激提示タイミングに同期した一過性の大きな活動（スパイク）が平常期の中に点在する（図**??**相当）．モデルは誤差全体の最小化を目指すため，出現頻度の低いスパイクを無視しがちであり，それがそのまま行動予測の誤差につながる．

スパース性 タスク中に活動する脳領域は全 ROI のごく一部である．単一被験者・単一 ROI の時系列は短く，学習に使える特徴量が少ない．

個人差の大きさ 同じタスクを実施しても，被験者ごとに活動パターンが大きく異なる．そのまま複数被験者のデータを混合すると，むしろ予測精度が低下することがある．

1.2　使用データセット

■HCP (Human Connectome Project) Young Adult

- 被験者数：1,200 名（健常若年成人，22–35 歳）
- タスク fMRI：WorkingMemory タスク（2-back, 0-back，LR/RL 2 方向）
- fMRI 仕様：2.0 mm isotropic，TR = 720 ms，全脳 72 スライス，405 時点
- 行動データ：条件別の正答率・反応時間が被験者ごとに取得済み
- 予測ターゲット：2-back 条件の平均正答率 $y^{\mathrm{acc}} \in [0.5, 1.0]$ と中央値反応時間 $y^{\mathrm{rt}} \in [400, 1200]\,\mathrm{ms}$ の 2 変数

■ターゲット変数の標準化【修正 1】 正答率と反応時間はスケールが約 10^3 倍異なるため，単純な L_2 損失では反応時間の誤差が勾配を支配する．訓練セットの平均・標準偏差で各変数を事前に標準化し，予測・損失計算はすべて標準化空間で行う：

$$\tilde{y}_i^{(\cdot)} = \frac{y_i^{(\cdot)} - \mu_{(\cdot)}}{\sigma_{(\cdot)}}, \quad (\cdot) \in \{\mathrm{acc}, \mathrm{rt}\} \tag{1}$$

$\mu_{(\cdot)}, \sigma_{(\cdot)}$ は訓練被験者のみから算出し，評価指標は逆変換後の値で報告する．

■事前学習済みエンコーダ：SwiFT（NeurIPS 2023） SwiFT は 4D volumetric fMRI を入力とする Swin Transformer であり，HCP・ABCD・UKBiobank の大規模データで事

前学習されている．本研究ではその重みを凍結し，固定特徴抽出器として用いる．

$$\boldsymbol{z}_i^{(t)} = f_{\mathrm{SwiFT}}\left(\boldsymbol{x}_i^{(t)}\right) \in \mathbb{R}^{288}, \quad \boldsymbol{x}_i^{(t)} \in \mathbb{R}^{96\times96\times96} \tag{2}$$

ここで i は被験者インデックス，t はウィンドウインデックスを表す．

2　課題：既存手法の限界

2.1　既存手法 1：単純な時系列予測モデル

最もシンプルなアプローチは，各被験者の $\boldsymbol{z}_i^{(t)}$ を軽量な encoder + 予測ヘッドに通し，行動ラベルを予測することである：

$$\boldsymbol{h}_i^{(t)} = f_{\mathrm{enc}}\left(\boldsymbol{z}_i^{(t)}\right) \in \mathbb{R}^{128} \tag{3}$$

$$\hat{\boldsymbol{y}}_i^{(t)} = f_{\mathrm{head}}\left(\boldsymbol{h}_i^{(t)}\right) \in \mathbb{R}^{2} \tag{4}$$

損失関数は

$$\mathcal{L}_{\mathrm{task}} = \frac{1}{N}\sum_{i=1}^{N}\frac{1}{T_i}\sum_{t=1}^{T_i}\left\|\hat{\boldsymbol{y}}_i^{(t)} - \boldsymbol{y}_i\right\|_2^2 \tag{5}$$

この手法の限界は，**各被験者のデータのみ**を使う点にある．スパースなタイムポイントや低頻度のスパイクは，単一被験者の短い時系列だけでは学習が困難である．

2.2　既存手法 2：RAF による他者参照

Retrieval-Augmented Forecasting（RAF）は，予測時に類似した他の時系列を検索して参照することで，単一系列の情報不足を補う手法である．

$$\boldsymbol{h}_{\mathrm{ret},i} = \mathrm{Retrieve}(\boldsymbol{h}_{q,i},\, \mathcal{M}) \tag{6}$$

ここで $\mathcal{M}$ はメモリバンク（全被験者の隠れ状態の集合），$\boldsymbol{h}_{q,i}$ はクエリとなる被験者 i の隠れ状態である．参照された $\boldsymbol{h}_{\mathrm{ret},i}$ と自己の $\boldsymbol{h}_{q,i}$ を組み合わせることで，スパイクや稀なパターンをより精度よく予測できる可能性がある．

■問題点：個人差による参照品質の低下　しかし素朴な RAF には致命的な欠陥がある．被験者間で h 空間の基準（スケール・方向）が揃っていないため，コサイン距離で検索しても「本当に似ている被験者」を見つけられず，ノイズの多い参照先を引っ張ってきてしまう（図**??**相当）．さらに，連続時系列を想定した RAF に対し，別被験者の時系列は本質的に不連続であるため，そのまま結合するとモデルの学習が不安定になる．

■結論　「参照が有効に機能するためには，まず h 空間を整地する必要がある」．類似した被験者が h 空間上でも近傍に集まっていれば，検索は正しく機能し，Gate 機構で不適切な参照を棄却することも可能になる．

3　解決手段：2 段階バブル型 GateRAF

3.1　全体設計の概要

本研究では以下の 2 段階設計を提案する：

Phase 1（空間整地）	$\longrightarrow$	**Phase 2（参照学習）**
対照学習で h 空間をバブル構造に整地		整地された空間で GateRAF を学習

この分業が必要な理由は **Moving Target 問題**にある．Phase 1 では Split/Merge によりバブルメンバーが変動し続けるため，Gate 層を同時に学習させると入力分布が非定常となり収束しない．バブルが安定した後に Gate 層を学習することで，この問題を回避する．

3.2　記号の定義

3.3　Phase 1：対照学習によるバブル形成

アーキテクチャ

$$\boldsymbol{z}_i^{(t)} \xrightarrow{f_{\text{enc}}} \boldsymbol{h}_i^{(t)} \in \mathbb{R}^{128} \xrightarrow{f_{\text{head}}} \hat{\boldsymbol{y}}_i^{(t)} \in \mathbb{R}^2 \tag{7}$$

$$\boldsymbol{h}_i^{(t)} = \mathrm{ReLU}\Big(\mathrm{LN}\Big(\boldsymbol{W}_e\, \boldsymbol{z}_i^{(t)} + \boldsymbol{b}_e\Big)\Big), \quad \boldsymbol{W}_e \in \mathbb{R}^{128\times 288} \tag{8}$$

$$\hat{\boldsymbol{y}}_i^{(t)} = \boldsymbol{W}_h\, \boldsymbol{h}_i^{(t)} + \boldsymbol{b}_h, \quad \boldsymbol{W}_h \in \mathbb{R}^{2\times 128} \tag{9}$$

$$\bar{\boldsymbol{h}}_i = \frac{1}{T_i}\sum_{t=1}^{T_i} \boldsymbol{h}_i^{(t)} \tag{10}$$

ラウンドループ（ラウンド $r = 1, \ldots, R$）

Step 1 — Frozen Keys の計算（`no_grad`）

ラウンド先頭で encoder を固定し，各バブルのプロトタイプを計算する：

$$\bar{\boldsymbol{h}}_i^{\text{frozen}} = \frac{1}{T_i}\sum_{t} f_{\text{enc}}\Big(\boldsymbol{z}_i^{(t)}\Big) \quad \forall\, i \tag{11}$$

$$\boldsymbol{c}_B^{(r)} = \frac{1}{|B|}\sum_{i\in B} \bar{\boldsymbol{h}}_i^{\text{frozen}} \quad \forall\, B \in \mathcal{B} \tag{12}$$

記号	意味
N	被験者数
$i \in \{1, \ldots, N\}$	被験者インデックス
T_i	被験者 i の fMRI ウィンドウ数
$\boldsymbol{z}_i^{(t)} \in \mathbb{R}^{288}$	SwiFT 出力（凍結）
$\boldsymbol{h}_i^{(t)} \in \mathbb{R}^{128}$	encoder 出力
$\bar{\boldsymbol{h}}_i \in \mathbb{R}^{128}$	被験者 i の h ウィンドウ平均
$\boldsymbol{c}_B \in \mathbb{R}^{128}$	バブル B のプロトタイプ
B_i	被験者 i が属するバブル
$\mathcal{B}$	バブルの集合，$K = \lvert\mathcal{B}\rvert$
$\tilde{y}_i^{(\cdot)}$	標準化後のターゲット変数
$\mu_{(\cdot)}$, $\sigma_{(\cdot)}$	ターゲット変数の訓練セット平均・標準偏差
τ	InfoNCE 温度パラメータ
λ	対照学習の重み
θ_{split}, θ_{merge}	Split/Merge の閾値
r_{anneal}	Split 閾値のアニーリング率
$d_{\text{avg}}(B)$	バブル内プロトタイプ平均距離（Split 判定用）
m	Momentum Encoder の慣性係数

Step 2 ― 損失計算と勾配更新

コサイン類似度を $\mathrm{sim}(\boldsymbol{a}, \boldsymbol{b}) = \boldsymbol{a}^\top \boldsymbol{b} / (\|\boldsymbol{a}\| \, \|\boldsymbol{b}\|)$ と定義する．タスク損失と InfoNCE 損失を以下で計算する：

$$\mathcal{L}_{\text{task}} = \frac{1}{N} \sum_{i=1}^{N} \frac{1}{T_i} \sum_{t=1}^{T_i} \left\| \hat{\tilde{\boldsymbol{y}}}_i^{(t)} - \tilde{\boldsymbol{y}}_i \right\|_2^2 \tag{13}$$

$$\mathcal{L}_{\text{con}} = \frac{1}{N} \sum_{i=1}^{N} \left[-\log \frac{\exp\left(\mathrm{sim}\left(\bar{\boldsymbol{h}}_i, \, \boldsymbol{c}_{B_i}^{(r)} \right) / \tau \right)}{\sum_{B' \in \mathcal{B}} \exp\left(\mathrm{sim}\left(\bar{\boldsymbol{h}}_i, \, \boldsymbol{c}_{B'}^{(r)} \right) / \tau \right)} \right] \tag{14}$$

$$\mathcal{L} = \mathcal{L}_{\text{task}} + \lambda \, \mathcal{L}_{\text{con}} \tag{15}$$

$$\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} - \eta \, \nabla_{\boldsymbol{\theta}} \, \mathcal{L}, \quad \boldsymbol{\theta} = \{ \boldsymbol{W}_e, \, \boldsymbol{b}_e, \, \boldsymbol{W}_h, \, \boldsymbol{b}_h \} \tag{16}$$

$\mathcal{L}_{\text{con}}$ は「自バブルのプロトタイプに引き寄せ，他バブルのプロトタイプから遠ざける」圧力を h 空間に与える．$\lambda = 0$ のとき $\mathcal{L}_{\text{con}} = 0$ となり，ベースライン（対照学習なし）と等価になる．

Step 3 — バブル管理

コサイン距離を $d(\boldsymbol{a}, \boldsymbol{b}) = 1 - \mathrm{sim}(\boldsymbol{a}, \boldsymbol{b}) \in [0,\, 2]$ と定義する．

Reassign（毎 3 ラウンド）：各被験者を最近傍プロトタイプへ再割り当てする：

$$B_i \leftarrow \arg\min_{B \in \mathcal{B}} d\big(\bar{\boldsymbol{h}}_i,\, \boldsymbol{c}_B\big) \quad \forall\, i \tag{17}$$

Split（毎 5 ラウンド）：プロトタイプからの平均距離が閾値を超え，かつ分割後の両バブルが最小サイズを満たす場合に 2 分割する【修正 2・3】：

$$\begin{aligned}
d_{\mathrm{avg}}(B) &= \frac{1}{|B|} \sum_{i \in B} d\big(\bar{\boldsymbol{h}}_i,\, \boldsymbol{c}_B\big) \qquad (18)\\
(i^*,\, j^*) &= \arg\max_{i,\, j \in B} d\big(\bar{\boldsymbol{h}}_i,\, \bar{\boldsymbol{h}}_j\big)\\
&\quad B_A = \big\{\ell \in B : d\big(\bar{\boldsymbol{h}}_\ell,\, \bar{\boldsymbol{h}}_{i^*}\big) \le d\big(\bar{\boldsymbol{h}}_\ell,\, \bar{\boldsymbol{h}}_{j^*}\big)\big\}, \quad B_B = B \setminus B_A\\
&\quad \text{if } \ d_{\mathrm{avg}}(B) > \theta_{\mathrm{split}} \ \text{ AND } \ |B_A| > k+1 \ \text{ AND } \ |B_B| > k+1 :\\
&\qquad \mathcal{B} \leftarrow \mathcal{B} \setminus \{B\} \cup \{B_A,\, B_B\}\\
&\qquad \theta_{\mathrm{split}} \leftarrow r_{\mathrm{anneal}} \cdot \theta_{\mathrm{split}} \quad \text{（過分割抑制のためのアニーリング）}
\end{aligned}$$

$d_{\max}$ の代わりに d_{avg} を用いることで，外れ値 1 名によるノイジーな過分割を防ぐ．分割点の探索（(i^*, j^*)）には引き続き最遠ペアを用いる．また $|B_A| > k+1$ かつ $|B_B| > k+1$ の制約により，Phase 2 の top-k 検索に必要な最小サイズを保証する．

Merge（毎 10 ラウンド）：プロトタイプが接近したバブルを統合する：

$$d(\boldsymbol{c}_A,\, \boldsymbol{c}_B) < \theta_{\mathrm{merge}} \ \Rightarrow \ \mathcal{B} \leftarrow \mathcal{B} \setminus \{B\}, \quad A \leftarrow A \cup B \tag{19}$$

Phase 1 の出力

$$\boldsymbol{\theta}^* = \{\boldsymbol{W}_e^*,\, \boldsymbol{b}_e^*,\, \boldsymbol{W}_h^*,\, \boldsymbol{b}_h^*\} \quad \text{（}\texttt{model.pt}\text{）} \tag{20}$$

$$\mathcal{B}^* = \{B_1^*,\, \ldots,\, B_K^*\} \quad \text{（}\texttt{final_bubbles.json}\text{）} \tag{21}$$

$$\mathcal{M} = \big\{\bar{\boldsymbol{h}}_i^* : i \in \{1, \ldots, N\}\big\}, \quad \bar{\boldsymbol{h}}_i^* = \frac{1}{T_i} \sum_t f_{\mathrm{enc}}^*\Big(\boldsymbol{z}_i^{(t)}\Big) \tag{22}$$

この段階では他者への参照は一切行わない．モデルは自分自身の $\boldsymbol{z}_i^{(t)}$ だけを使って学習するため，空間が未整地な初期状態でも学習が崩壊しない．

3.4 Phase 2：GateRAF による参照学習

Phase 1 の完了後，$\boldsymbol{\theta}^*$ と $\mathcal{B}^*$ をロードして Phase 2 を開始する．この時点で h 空間は整地されており，安全に他者の情報を参照できる．

アーキテクチャ

$$\boldsymbol{z}_i^{(t)} \xrightarrow{f^*_{\text{enc}}} \boldsymbol{h}_{q,i}^{(t)} \xrightarrow{\text{Memory Bank 検索}} \boldsymbol{h}_{\text{ret},i} \xrightarrow{\text{Gate}} g_i \xrightarrow{\text{Fusion}} \boldsymbol{h}_{\text{fused},i} \xrightarrow{f'_{\text{head}}} \hat{\boldsymbol{y}}_i \tag{23}$$

Memory Bank 検索【修正 3】

バブル内の上位 k 件をコサイン類似度で検索し集約する．バブルサイズが不足する場合（Phase 1 の制約をすり抜けた孤立被験者等）はゼロベクトルにフォールバックし，Gate が自動的に参照を棄却できるようにする：

$$\bar{\boldsymbol{h}}_{q,i} = \frac{1}{T_i} \sum_t f^*_{\text{enc}}\Big(\boldsymbol{z}_i^{(t)}\Big) \tag{24}$$

$$\mathcal{N}_i = \text{top-}\,k_{j \in B_i^*,\, j \neq i}\ \text{sim}\big(\bar{\boldsymbol{h}}_{q,i},\, \bar{\boldsymbol{h}}_j^*\big) \tag{25}$$

$$\boldsymbol{h}_{\text{ret},i} = \begin{cases} \dfrac{1}{|\mathcal{N}_i|} \displaystyle\sum_{j \in \mathcal{N}_i} \bar{\boldsymbol{h}}_j^* & |B_i^*| > k+1 \\ \boldsymbol{0} & \text{otherwise} \end{cases} \in \mathbb{R}^{128} \tag{26}$$

$\boldsymbol{h}_{\text{ret},i} = \boldsymbol{0}$ のとき Fusion は $\boldsymbol{h}_{\text{fused},i} = \bar{\boldsymbol{h}}_{q,i} + g_i \cdot \boldsymbol{0} = \bar{\boldsymbol{h}}_{q,i}$ に退化し，孤立被験者は参照なしの予測に自動的に切り替わる．

Gate 層（学習対象）

$$g_i = \sigma\big(\text{MLP}_{\text{gate}}\big([\bar{\boldsymbol{h}}_{q,i};\, \boldsymbol{h}_{\text{ret},i}]\big)\big) \in [0,\, 1], \quad \text{MLP}_{\text{gate}} : \mathbb{R}^{256} \to \mathbb{R} \tag{27}$$

$g_i \approx 1$ のとき参照情報を積極的に取り込み，$g_i \approx 0$ のとき参照を棄却する（自己完結で予測する）．

Fusion 層（学習対象）

$$\boldsymbol{h}_{\text{fused},i} = \bar{\boldsymbol{h}}_{q,i} + g_i \cdot \boldsymbol{h}_{\text{ret},i} \in \mathbb{R}^{128} \tag{28}$$

予測ヘッド（学習対象）

$$\hat{\boldsymbol{y}}_i = \boldsymbol{W}'_h\, \boldsymbol{h}_{\text{fused},i} + \boldsymbol{b}'_h \in \mathbb{R}^2 \tag{29}$$

学習ループ

バブル構成は Phase 1 の結果で完全に固定する（$\mathcal{B}^* = \text{const.}$）．対照学習は停止し，タスク損失のみで Gate 層と予測ヘッドを学習する：

$$\boldsymbol{\phi} = \{\boldsymbol{\theta}_{\text{gate}},\, \boldsymbol{W}'_h,\, \boldsymbol{b}'_h\} \tag{30}$$

$$\mathcal{L}_{\text{Phase2}} = \frac{1}{N}\sum_{i=1}^{N}\left\|\hat{\tilde{\boldsymbol{y}}}_i - \tilde{\boldsymbol{y}}_i\right\|_2^2 \tag{31}$$

$$\boldsymbol{\phi} \leftarrow \boldsymbol{\phi} - \eta'\,\nabla_{\boldsymbol{\phi}}\,\mathcal{L}_{\text{Phase2}} \tag{32}$$

「同一バブル内の他者情報を Gate で通した方が $\mathcal{L}_{\text{Phase2}}$ が下がる」という純粋な目的に沿って Gate の開閉ルールが学習される．

■エンコーダ凍結の設計根拠と代替案【修正 4】 Phase 2 でエンコーダ f^*_{enc} を凍結する理由は，メモリバンク $\mathcal{M}$ との表現整合性を保つためである．エンコーダを更新すると，クエリ表現 $\bar{\boldsymbol{h}}_{q,i}$ とメモリバンク内の $\bar{\boldsymbol{h}}^*_j$（Phase 1 の encoder で計算済み）の空間がずれ，コサイン類似度検索が無効化される（**表現ドリフト問題**）．
表現力のさらなる向上が必要な場合は，MoCo 方式の Momentum Encoder を導入する：

$$\boldsymbol{\theta}^{\text{key}}_{\text{enc}} \leftarrow m\,\boldsymbol{\theta}^{\text{key}}_{\text{enc}} + (1-m)\,\boldsymbol{\theta}^{\text{query}}_{\text{enc}}, \quad m \approx 0.99 \tag{33}$$

クエリ encoder $\boldsymbol{\theta}^{\text{query}}_{\text{enc}}$ は通常の勾配更新，メモリバンク用の key encoder $\boldsymbol{\theta}^{\text{key}}_{\text{enc}}$ はモーメンタム追従とすることで，検索空間の整合性を維持しつつエンコーダの表現力も向上させられる．実験上はまず凍結版で baseline を確立し，改善が不十分であれば Momentum Encoder に移行する段階的アブレーションを採用する．

4 予想される成果

4.1 比較実験の設計

本提案の有効性を検証するため，以下の 3 条件を比較する：

条件	Phase 1	Phase 2	検証する仮説
A	$\lambda = 0$（対照学習なし）	GateRAF	バブル整地の寄与
B	$\lambda > 0$（対照学習あり）	GateRAF	**本提案**
C	$\lambda > 0$（対照学習あり）	なし	参照機構の寄与

条件 B > 条件 A であれば「h 空間の整地が参照精度を高める」ことが示される．
条件 B > 条件 C であれば「バブル内参照が予測を向上させる」ことが示される．

4.2 期待される効果

1. **スパイク予測精度の向上**
   バブル内の類似被験者の隠れ状態を参照することで，単一被験者データでは捉えにくいスパイク直前のパターンを補完できる．これにより条件 B は条件 A・C に比べてスパイク周辺の MSE が低下すると期待される．
2. **ノイズ低減**
   参照範囲をバブル内に限定することで，h 空間が遠い（＝認知パターンが異なる）被験者の情報が混入しない．Gate 機構がさらに参照の質を保証する．
3. **h 空間の凝集性・分離性の向上**
   $\mathcal{L}_{\mathrm{con}}$ により，同一バブル内の $\bar{\boldsymbol{h}}_i$ は互いに引き寄せられ，異バブルの $\bar{\boldsymbol{h}}_i$ とは遠ざかる．これは Split/Merge の判定精度を高め，バブル構成を安定させる．
4. **Gate の正則化効果**
   有用な参照のみを取り込む Gate 機構は，少ないデータ量でも過適合を抑えるドロップアウト的な効果を持つ可能性がある．