研究計画：バブル型クラスタ学習による GateRAF 強化と脳 fMRI タスク予測

目次

1　なぜ GateRAF か

タスク実行中の脳 fMRI 時系列データは以下の性質を持ち，通常の予測モデルでは対処が難しい．

■ fMRI データは ROI × 被験者の組み合わせで膨大な数の時系列が存在する．単一被験者・単一 ROI のデータ量は限られていても，系列の総数は多い．他の被験者・ROI の系列を参照することで情報不足を補える．RAF はこの「横断的な参照」を可能にするアーキテクチャである．

系列の多さ

■タスク中の神経応答は BOLD 信号として現れ，刺激提示タイミングに同期したスパイク状の一過性の活動が平常期の中に点在する．予測モデルは誤差全体を最小化しようとするため，頻度の低いスパイクを無視しがちである．スパイク直前の予兆（トリガー）を他被験者の類似タスク事例から参照することで補完できる．

スパイク

■タスク中に活動する脳領域は全 ROI のごく一部であり，時系列はスパースである．スパースな系列では時系列モデルが学習できる特徴量が少ない．似た脳ネットワーク特性を持つ被験者の隠れ状態を参照して補完できる．

スパース

■似ていない系列を強制的に参照してしまうとノイズになる．異なる被験者の時系列を結合すると時系列が不連続になる．Gate で不適切な参照を棄却し，Multi-Stream で系列を分離する GateRAF が必要である．

シンプルな RAF では不十分な理由

■ fMRI 時系列は個人差が激しく，同じタスクでも被験者間で活動パターンが異なる．個人差によってベクトル空間の基準がずれ，参照がさらに機能しにくい．バブル型クラスタ学習で空間を整地することが不可欠である．

脳データ固有の追加課題

2　研究の核心：2 段階設計

「空間を整えながら，同時に他者を参照する」という不安定なことはしない．

Phase 1（空間整地）	$\longrightarrow$	**Phase 2（参照学習）**
自力でタスクを解きながら		整った空間と固定バブルを
h 空間をバブル構造に整地		使って，安全に他者を参照

■ Phase 1 ではラウンドごとに Split/Merge が発生し，バブルメンバーが変動する．この

状態で Gate 層を同時に学習させると，検索対象（入力分布）が常に変化するため，Gate 層は「いつ開くか」のルールを学習できず，重みが収束しない．Phase 1 でバブルを完全に固定してから，Phase 2 で Gate を学習するという分業が不可欠である．

2 段階が必須な理由：Moving Target 問題

3 Phase 1：バブル形成（実装済み）

目標

被験者の生理的・認知的特性に基づくバブル（クラスタ）を形成し，似た者同士が同じバブルに集まった「安全で整頓された h 空間」を構築する．

モデル構成

$$\boldsymbol{z} \in \mathbb{R}^{288} \xrightarrow{\text{encoder}} \boldsymbol{h} \in \mathbb{R}^{128} \xrightarrow{\text{head}} \left[\hat{y}_{\text{acc}},\, \hat{y}_{\text{rt}}\right]$$

$$\text{encoder} = \text{Linear}(288 \to 128) \to \text{LayerNorm} \to \text{ReLU}$$

ファイル構成

`precompute.py`	SwiFT に全被験者の fMRI を通し，$\boldsymbol{z}$ を `data/` にキャッシュ
`dataset.py`	キャッシュ済み $\boldsymbol{z}$ と行動ラベル（acc/RT）の読み込み
`client_model.py`	encoder + 予測ヘッドの定義（`ClientModel`）
`bubble_manager.py`	バブル管理：プロトタイプ・InfoNCE 損失・Reassign・Split・Merge
`train.py`	メインループ（60 ラウンド）．結果を `results/` に保存

1 ラウンドの処理フロー

1. **Frozen Keys の計算**（`no_grad`）
2. **勾配ありの学習**（LOCAL_EPOCHS 回繰り返し）
3. **評価**（`no_grad`，全被験者）：各被験者の eval_loss を記録
4. **バブル管理**（スケジュールに従って実行）：毎 3 ラウンド Reassign，毎 5 ラウンド Split，毎 10 ラウンド Merge

Phase 1 では「参照」をしていない

このフェーズでは他者のデータを検索・参照する機能（Retrieval）は一切ない．モデルは自分自身の $\boldsymbol{z}$ だけを使って自力でタスクを予測しながら h 空間を整地する．

4　Phase 2：GateRAF（実装予定）

Phase 1 の 60 ラウンドが完了し，`model.pt` と `final_bubbles.json` をロードして開始する．GateRAF が初めて他者の情報を参照するその瞬間には，すでに「似た者同士が同じバブルに集まった，安全で整頓された空間」が約束されている．

新しいモデル構成

$$\boldsymbol{z} \xrightarrow{f^*_{\mathrm{enc}}} \boldsymbol{h}_q \xrightarrow{\text{Memory Bank 検索}} \boldsymbol{h}_{\mathrm{ret}} \xrightarrow{\text{Gate}} g \in [0,1] \xrightarrow{\text{Fusion}} \boldsymbol{h}_{\mathrm{fused}} \xrightarrow{\mathrm{head}'} \hat{\boldsymbol{y}}$$

Phase 2 の学習環境（Phase 1 との違い）

- 検索プールの完全固定：`final_bubbles.json` を絶対的な DB として使用，バブル変動なし
- 対照学習の完全停止：$\mathcal{L}_{\mathrm{con}}$ は計算しない（空間整地は完了済み）
- 純粋なタスク損失：$\mathcal{L} = \mathcal{L}_{\mathrm{task}} = \mathrm{MSE}(\hat{\boldsymbol{y}}, \boldsymbol{y})$ のみ
- 学習目標：「同一バブル内の他者情報を Gate で通した方が $\mathcal{L}_{\mathrm{task}}$ が下がる」ことを学習

5　ベースラインとの比較

	$\lambda = 0$（対照学習なし）	$\lambda > 0$（対照学習あり，本提案）
バブル判定の根拠	h の分散（受動的観測）	InfoNCE 損失（能動的整形）
h 空間への介入	なし	あり（バブル構造に向けて学習）
バブル内の凝集性	学習の副産物	損失関数が明示的に保証
バブル間の分離性	学習の副産物	損失関数が明示的に保証
損失関数（Phase 1）	$\mathcal{L}_{\mathrm{task}}$ のみ	$\mathcal{L}_{\mathrm{task}} + \lambda\,\mathcal{L}_{\mathrm{con}}$
sweep の対象	$\theta_{\mathrm{split}}, \theta_{\mathrm{merge}}$	$+\lambda, \tau$

■

A. Phase 1（$\lambda = 0$）+ Phase 2（GateRAF）　← バブルなし参照
B. Phase 1（$\lambda > 0$）+ Phase 2（GateRAF）　← バブルあり参照（本提案）
C. Phase 1（$\lambda > 0$）のみ　← 参照なし予測（上限確認）

6　使用データセット

比較実験の構成

■

- 被験者数：1,200 名（健常若年成人，22–35 歳）
- タスク fMRI：WorkingMemory タスク（N-back，LR/RL 2 方向）を使用
- fMRI 仕様：2.0mm isotropic，TR = 720ms，全脳 72 スライス，405 時点
- 行動データ：条件別反応時間・正答率が被験者ごとに取得済み

■

- 4D volumetric fMRI を入力とする Swin Transformer
- HCP・ABCD・UKBiobank で学習済み
- 入力：$(B, 1, 96, 96, 96, 20)$，出力 pooling で $\boldsymbol{z} \in \mathbb{R}^{288}$
- 凍結して使用し，encoder 層と予測ヘッドのみ学習（Phase 1）

7　完全な数式記述

事前学習済みエンコーダ：SwiFT（NeurIPS 2023）

7.1　記号の定義

7.2　データ前処理

SwiFT（凍結）による特徴抽出：

$$\boldsymbol{z}_i^{(t)} = f_{\mathrm{SwiFT}}\Big(\boldsymbol{x}_i^{(t)}\Big) \in \mathbb{R}^{288} \tag{1}$$

7.3　Phase 1 アーキテクチャ

■

$$\boldsymbol{h}_i^{(t)} = \mathrm{ReLU}\Big(\mathrm{LN}\Big(\boldsymbol{W}_e\, \boldsymbol{z}_i^{(t)} + \boldsymbol{b}_e\Big)\Big) \in \mathbb{R}^{128}, \quad \boldsymbol{W}_e \in \mathbb{R}^{128\times 288} \tag{2}$$

Encoder（学習対象）

■

$$\bar{\boldsymbol{h}}_i = \frac{1}{T_i}\sum_{t=1}^{T_i} \boldsymbol{h}_i^{(t)} \in \mathbb{R}^{128} \tag{3}$$

記号	意味
N	被験者数
$i \in \{1, \ldots, N\}$	被験者インデックス
T_i	被験者 i の fMRI ウィンドウ数
$t \in \{1, \ldots, T_i\}$	ウィンドウインデックス
$\boldsymbol{x}_i^{(t)} \in \mathbb{R}^{96\times96\times96}$	fMRI ボリューム（1 ウィンドウ）
$\boldsymbol{y}_i \in \mathbb{R}^2$	行動ラベル $[y_i^{\mathrm{acc}}, y_i^{\mathrm{rt}}]$
$\boldsymbol{z}_i^{(t)} \in \mathbb{R}^{288}$	SwiFT 出力（凍結）
$\boldsymbol{h}_i^{(t)} \in \mathbb{R}^{128}$	encoder 出力（学習対象）
$\bar{\boldsymbol{h}}_i \in \mathbb{R}^{128}$	被験者 i の h ウィンドウ平均
$\boldsymbol{c}_B \in \mathbb{R}^{128}$	バブル B のプロトタイプ
B_i	被験者 i が属するバブル
$\mathcal{B}$	バブルの集合
$K = \lvert\mathcal{B}\rvert$	バブル数
τ	InfoNCE 温度パラメータ
λ	対照学習の重み
$\theta_{\mathrm{split}}, \theta_{\mathrm{merge}}$	Split/Merge の閾値
r_{anneal}	Split 閾値のアニーリング率

被験者レベル表現（ウィンドウ平均）

■

$$\hat{\boldsymbol{y}}_i^{(t)} = \boldsymbol{W}_h\, \boldsymbol{h}_i^{(t)} + \boldsymbol{b}_h \in \mathbb{R}^2, \quad \boldsymbol{W}_h \in \mathbb{R}^{2\times128} \tag{4}$$

予測ヘッド（学習対象）

7.4 Phase 1 ラウンドループ（ラウンド r）

ステップ 1：Frozen Keys の計算（`no_grad`）

$$\bar{\boldsymbol{h}}_i^{\mathrm{frozen}} = \frac{1}{T_i} \sum_{t=1}^{T_i} f_{\mathrm{enc}}\Big(\boldsymbol{z}_i^{(t)}\Big) \quad \forall\, i \tag{5}$$

$$\boldsymbol{c}_B^{(r)} = \frac{1}{\lvert B\rvert} \sum_{i\in B} \bar{\boldsymbol{h}}_i^{\mathrm{frozen}} \quad \forall\, B \in \mathcal{B} \tag{6}$$

ステップ 2：勾配ありの学習（LOCAL_EPOCHS 回）

コサイン類似度：

$$\mathrm{sim}(\boldsymbol{a}, \boldsymbol{b}) = \frac{\boldsymbol{a}^\top \boldsymbol{b}}{\|\boldsymbol{a}\| \, \|\boldsymbol{b}\|} \tag{7}$$

タスク損失（MSE）：

$$\mathcal{L}_{\mathrm{task}} = \frac{1}{N} \sum_{i=1}^{N} \frac{1}{T_i} \sum_{t=1}^{T_i} \left\| \hat{\boldsymbol{y}}_i^{(t)} - \boldsymbol{y}_i \right\|_2^2 \tag{8}$$

InfoNCE 損失（プロトタイプ $K = |\mathcal{B}|$ 個）：

$$\mathcal{L}_{\mathrm{con}} = \frac{1}{N} \sum_{i=1}^{N} \left[-\log \frac{\exp\Big(\mathrm{sim}\Big(\bar{\boldsymbol{h}}_i,\, \boldsymbol{c}_{B_i}^{(r)}\Big) / \tau\Big)}{\sum_{B' \in \mathcal{B}} \exp\Big(\mathrm{sim}\Big(\bar{\boldsymbol{h}}_i,\, \boldsymbol{c}_{B'}^{(r)}\Big) / \tau\Big)} \right] \tag{9}$$

総損失：

$$\mathcal{L} = \mathcal{L}_{\mathrm{task}} + \lambda \, \mathcal{L}_{\mathrm{con}} \tag{10}$$

パラメータ更新（Adam）：

$$\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} - \eta \, \nabla_{\boldsymbol{\theta}} \mathcal{L}, \quad \boldsymbol{\theta} = \{\boldsymbol{W}_e,\, \boldsymbol{b}_e,\, \boldsymbol{W}_h,\, \boldsymbol{b}_h\} \tag{11}$$

ステップ 3：バブル管理

コサイン距離：

$$d(\boldsymbol{a}, \boldsymbol{b}) = 1 - \mathrm{sim}(\boldsymbol{a}, \boldsymbol{b}) \in [0,\, 2] \tag{12}$$

Reassign（毎 3 ラウンド）：

$$B_i \leftarrow \arg\min_{B \in \mathcal{B}} d\big(\bar{\boldsymbol{h}}_i,\, \boldsymbol{c}_B\big) \quad \forall\, i \tag{13}$$

Split（毎 5 ラウンド）：

$$d_{\max}(B) = \max_{i,\, j \in B} d\big(\bar{\boldsymbol{h}}_i,\, \bar{\boldsymbol{h}}_j\big) \tag{14}$$

$$\text{if } d_{\max}(B) > \theta_{\mathrm{split}} :$$

$$(i^*,\, j^*) = \arg\max_{i,\, j \in B} d\big(\bar{\boldsymbol{h}}_i,\, \bar{\boldsymbol{h}}_j\big) \tag{15}$$

$$B_A = \big\{ k \in B : d\big(\bar{\boldsymbol{h}}_k,\, \bar{\boldsymbol{h}}_{i^*}\big) \le d\big(\bar{\boldsymbol{h}}_k,\, \bar{\boldsymbol{h}}_{j^*}\big) \big\} \tag{16}$$

$$B_B = B \setminus B_A \tag{17}$$

$$\theta_{\mathrm{split}} \leftarrow r_{\mathrm{anneal}} \cdot \theta_{\mathrm{split}} \tag{18}$$

Merge（毎 10 ラウンド）：

$$d(\boldsymbol{c}_A,\, \boldsymbol{c}_B) < \theta_{\mathrm{merge}} \;\Rightarrow\; \mathcal{B} \leftarrow \mathcal{B} \setminus \{B\}, \quad A \leftarrow A \cup B \tag{19}$$

7.5 Phase 1 の出力

$$\boldsymbol{\theta}^* = \{\boldsymbol{W}_e^*,\, \boldsymbol{b}_e^*,\, \boldsymbol{W}_h^*,\, \boldsymbol{b}_h^*\} \quad (\texttt{model.pt} \text{ に保存}) \tag{20}$$

$$\mathcal{B}^* = \{B_1^*,\, B_2^*,\, \ldots,\, B_K^*\} \quad (\texttt{final_bubbles.json} \text{ に保存}) \tag{21}$$

$$\mathcal{M} = \left\{\bar{\boldsymbol{h}}_i^* : i \in \{1, \ldots, N\}\right\}, \quad \bar{\boldsymbol{h}}_i^* = \frac{1}{T_i} \sum_t f_{\text{enc}}^*\left(\boldsymbol{z}_i^{(t)}\right) \quad (\text{no_grad}) \tag{22}$$

7.6 Phase 2 アーキテクチャ（GateRAF）

Memory Bank 検索

クエリ：

$$\boldsymbol{h}_{q,i}^{(t)} = f_{\text{enc}}^*\left(\boldsymbol{z}_i^{(t)}\right), \quad \bar{\boldsymbol{h}}_{q,i} = \frac{1}{T_i} \sum_t \boldsymbol{h}_{q,i}^{(t)} \tag{23}$$

バブル内 top-k 検索：

$$\mathcal{N}_i = \text{top-}\, k_{j \in B_i^*,\, j \neq i}\, \text{sim}\left(\bar{\boldsymbol{h}}_{q,i},\, \bar{\boldsymbol{h}}_j^*\right) \tag{24}$$

検索結果の集約：

$$\boldsymbol{h}_{\text{ret},i} = \frac{1}{k} \sum_{j \in \mathcal{N}_i} \bar{\boldsymbol{h}}_j^* \in \mathbb{R}^{128} \tag{25}$$

Gate 層（学習対象）

$$g_i = \sigma\left(\text{MLP}_{\text{gate}}\left(\left[\bar{\boldsymbol{h}}_{q,i};\, \boldsymbol{h}_{\text{ret},i}\right]\right)\right) \in [0,\, 1], \quad \text{MLP}_{\text{gate}} : \mathbb{R}^{256} \to \mathbb{R} \tag{26}$$

Fusion 層（学習対象）

$$\boldsymbol{h}_{\text{fused},i} = \bar{\boldsymbol{h}}_{q,i} + g_i \cdot \boldsymbol{h}_{\text{ret},i} \in \mathbb{R}^{128} \tag{27}$$

予測ヘッド（学習対象）

$$\hat{\boldsymbol{y}}_i = \boldsymbol{W}_h'\, \boldsymbol{h}_{\text{fused},i} + \boldsymbol{b}_h' \in \mathbb{R}^2 \tag{28}$$

7.7 Phase 2 学習ループ

学習対象パラメータ（encoder $\boldsymbol{\theta}^*$ は Freeze または微小 lr で Fine-tune）：

$$\boldsymbol{\phi} = \{\boldsymbol{\theta}_{\text{gate}},\, \boldsymbol{W}_h',\, \boldsymbol{b}_h'\} \tag{29}$$

タスク損失のみ（対照学習なし）：

$$\mathcal{L}_{\text{Phase2}} = \frac{1}{N}\sum_{i=1}^{N} \|\hat{\boldsymbol{y}}_i - \boldsymbol{y}_i\|_2^2 \tag{30}$$

パラメータ更新（Adam）：

$$\boldsymbol{\phi} \leftarrow \boldsymbol{\phi} - \eta' \nabla_{\boldsymbol{\phi}} \mathcal{L}_{\text{Phase2}} \tag{31}$$

バブル構成は固定：

$$\mathcal{B}^* = \text{const.} \tag{32}$$

8 期待される効果

- バブルなしの GateRAF と比較してスパイク検出精度の向上
- バブル内参照によるノイズ低減（無関係ユーザの除外）
- 対照学習により h 空間がバブル構造に向けて能動的に整形される（θ_{split}・θ_{merge} の判定精度向上，バブル構成の安定化）
- $\lambda = 0$ のベースラインとの比較実験により，対照学習の寄与を定量評価できる
- 2 段階設計により Gate 層の学習が安定する（Moving Target 問題を回避）